

Laporan Mata Kuliah Pemrosesan Bahasa Alami

**SKILLSCOPE ID: EKSTRAKSI KETERAMPILAN DAN
TEKNOLOGI PADA LOWONGAN KERJA INDONESIA
MENGUNAKAN NAMED ENTITY RECOGNITION
BERBASIS TRANSFORMER**

disusun untuk memenuhi tugas mata kuliah
Pemrosesan Bahasa Alami

oleh:

MUHAMMAD AIDIL FITRAH

2308107010035



**JURUSAN INFORMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS SYIAH KUALA
2026**

BAB I


PENDAHULUAN

1.1 Latar Belakang

Pasar kerja di Indonesia mengalami perkembangan yang pesat seiring digitalisasi industri dan pertumbuhan sektor teknologi informasi. Platform lowongan kerja seperti Jobstreet, Indeed, Loker.id, dan Job.Id setiap harinya memuat ribuan entri baru, masing-masing berisi persyaratan kualifikasi dan kompetensi yang dibutuhkan perusahaan. Namun, pencari kerja seringkali kesulitan mengidentifikasi keterampilan (skill) spesifik apa yang paling diminati pasar, sehingga terjadi kesenjangan (skill gap) antara kemampuan yang dimiliki dengan kebutuhan industri.

Analisis kebutuhan skill secara manual dari ribuan lowongan kerja tidak hanya membutuhkan waktu yang sangat lama, tetapi juga rentan terhadap inkonsistensi interpretasi. Pendekatan Pemrosesan Bahasa Alami (NLP) menawarkan solusi melalui otomatisasi ekstraksi informasi dari teks tidak terstruktur. Salah satu task NLP yang paling sesuai untuk permasalahan ini adalah Named Entity Recognition (NER), yaitu identifikasi dan klasifikasi span teks yang merepresentasikan entitas tertentu.

Proyek ini membangun sistem SkillScope ID, sebuah pipeline ekstraksi skill otomatis yang melakukan fine-tuning dua model transformer berbasis BERT—IndoBERT-Large dan NusaBERT-Large—menggunakan dataset NERSkill.Id yang berisi 4.299 kalimat lowongan kerja Indonesia yang telah dianotasi dengan skema BIO. Model terbaik kemudian dikonversi ke format ONNX dan di-deploy sebagai aplikasi web statis bertenaga browser-inference, memungkinkan demonstrasi langsung tanpa server backend.



Gambar 1.1. Arsitektur umum sistem SkillScope ID dari input teks lowongan kerja hingga output entitas skill yang diekstrak

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah proyek ini adalah:

1. Bagaimana membangun model NER berbasis transformer yang mampu mengenali hard skill, soft skill, dan teknologi dari teks lowongan kerja berbahasa Indonesia?
2. Model manakah yang memberikan performa lebih baik untuk task ini: IndoBERT-Large atau NusaBERT-Large?
3. Seberapa stabil performa model setelah dikonversi ke format ONNX dan dikuantisasi menjadi INT8?
4. Bagaimana menyajikan hasil ekstraksi skill secara interaktif melalui aplikasi web berbasis client-side inference?

1.3 Tujuan Penelitian

Proyek ini bertujuan untuk: (1) melakukan fine-tuning dua model transformer pre-trained untuk task token classification pada domain lowongan kerja Indonesia; (2) mengevaluasi dan membandingkan performa IndoBERT-Large dan NusaBERT-Large menggunakan metrik entity-level precision, recall, dan F1-score; (3) mengeksport model terbaik ke format ONNX dan melakukan kuantisasi INT8 untuk efisiensi deployment; serta (4) membangun aplikasi web demo statis yang menjalankan inferensi NER secara langsung di browser menggunakan ONNX Runtime Web tanpa memerlukan server backend.

1.4 Manfaat Penelitian

Manfaat proyek ini mencakup tiga pemangku kepentingan utama. Bagi pencari kerja, sistem ini membantu mengidentifikasi skill yang paling diminati pasar sehingga dapat menyusun strategi pengembangan diri yang lebih terarah. Bagi recruiter dan tim HR, sistem mempercepat proses parsing lowongan kerja dan menyediakan fondasi untuk sistem job-skill matching otomatis. Bagi komunitas akademik, proyek ini menunjukkan penerapan nyata fine-tuning model transformer pada task NER Bahasa Indonesia dalam domain yang relevan, serta proses end-to-end dari pelatihan model hingga deployment di browser.

BAB II

KAJIAN PUSTAKA

2.1 Information Extraction dan Named Entity Recognition

Information Extraction (IE) adalah cabang NLP yang bertugas mengekstrak informasi terstruktur dari teks tidak terstruktur. Sub-task paling mendasar dalam IE adalah Named Entity Recognition (NER), yang bertujuan mengidentifikasi dan mengklasifikasikan span teks ke dalam kategori entitas yang telah ditetapkan sebelumnya—seperti nama orang, lokasi, organisasi, atau kategori domain-spesifik (Nadeau & Sekine, 2007). Dalam konteks proyek ini, NER diaplikasikan untuk mengekstrak tiga kategori skill dari teks lowongan kerja: hard skill (keterampilan teknis terukur), soft skill (keterampilan interpersonal), dan technology (alat, framework, atau platform teknologi).

2.2 Skema Anotasi BIO Tagging

Pendekatan yang lazim digunakan dalam NER adalah skema BIO (Beginning, Inside, Outside) tagging. Setiap token dalam kalimat diberi salah satu dari tiga prefiks: B- (token awal sebuah entitas), I- (token lanjutan dari entitas yang sama), atau O (bukan bagian dari entitas apapun). Skema ini memungkinkan representasi entitas multi-kata secara eksplisit (Ratinov & Roth, 2009). Dalam proyek ini, label BIO yang digunakan adalah: B-HSkill, I-HSkill, B-SSkill, I-SSkill, B-Tech, I-Tech, dan O.

Token / Kata	Label BIO	Penjelasan / Kategori
Dicari	O	Bukan entitas
programmer	O	Bukan entitas
yang	O	Bukan entitas
menguasai	O	Bukan entitas
Python	B-Tech	Awal entitas Technology (Beginning)
dan	O	Bukan entitas

Token / Kata	Label BIO	Penjelasan / Kategori
memiliki	O	Bukan entitas
analisis	B-HSkill	Awal entitas Hard Skill (Beginning)
data	I-HSkill	Lanjutan entitas Hard Skill (Inside)
serta	O	Bukan entitas
komunikasi	B-SSkill	Awal entitas Soft Skill (Beginning)
yang	O	Bukan entitas
baik	O	Bukan entitas

Tabel 2.1. Contoh anotasi *BIO tagging* pada kalimat lowongan kerja Indonesia dengan tiga kategori entitas (HSkill, SSkill, Tech)

2.3 Transformer dan BERT

Arsitektur Transformer (Vaswani et al., 2017) merevolusi NLP dengan mekanisme self-attention yang menangkap dependensi jangka panjang dalam teks secara paralel dan efisien. BERT (Bidirectional Encoder Representations from Transformers) yang dikembangkan Devlin et al. (2019) memanfaatkan encoder Transformer dan melakukan pre-training pada korpus besar dengan dua objektif: Masked Language Model (MLM) dan Next Sentence Prediction (NSP). Kemampuan BERT menghasilkan representasi kontekstual bidireksional menjadikannya sangat efektif untuk berbagai task NLP downstream, termasuk NER, melalui fine-tuning. Untuk task NER, sebuah lapisan linear classification ditambahkan di atas output token BERT. Varian BERT-Large memiliki 24 lapisan transformer, 16 attention heads, dimensi hidden 1.024, dengan total sekitar 335 juta parameter.

2.4 IndoBERT-Large

IndoBERT adalah model bahasa berbasis BERT yang dilatih khusus untuk Bahasa Indonesia, dikembangkan dalam kerangka IndoNLU Benchmark oleh Wilie et al. (2020). Dataset pre-training mencakup artikel berita, Wikipedia Bahasa Indonesia, dan teks web. Varian large yang digunakan dalam proyek ini

(indobenchmark/indobert-large-p2) mewakili model spesialis Bahasa Indonesia dengan kapasitas representasi tinggi, sehingga diharapkan mampu menangkap nuansa linguistik teks lowongan kerja Indonesia.

2.5 NusaBERT-Large

NusaBERT adalah generasi penerus IndoBERT yang dikembangkan oleh LazarusNLP. Model ini dilatih ulang dengan corpus yang jauh lebih besar, mencapai 16 miliar token, yang mencakup berbagai ragam teks Bahasa Indonesia. Dengan volume data pre-training yang lebih besar tersebut, NusaBERT diharapkan memiliki representasi semantik yang lebih kaya. Varian large (LazarusNLP/NusaBERT-large) digunakan sebagai model pembanding dalam proyek ini, dengan arsitektur BERT-Large yang setara dengan IndoBERT-Large.

2.6 Dataset NERSkill.Id

NERSkill.Id adalah dataset NER untuk ekstraksi skill dari lowongan kerja Indonesia yang dipublikasikan di Mendeley Data (DOI: 10.17632/5s8r9ndfvc.1). Dataset ini dikumpulkan dari berbagai platform lowongan kerja Indonesia, yaitu Indeed, Jobstreet, Loker.id, dan Job.Id. Anotasi dilakukan pada tingkat token menggunakan skema BIO dengan tiga kategori entitas: hard skill, soft skill, dan technology. Dataset ini merupakan sumber daya yang langka untuk task spesifik ini dalam Bahasa Indonesia, menjadikannya pilihan utama sebagai basis pelatihan model SkillScope ID.

2.7 ONNX Runtime dan Client-Side Deployment


Open Neural Network Exchange (ONNX) adalah format representasi model machine learning yang terbuka dan interoperable, memungkinkan model yang dilatih dengan satu framework (PyTorch) untuk dieksekusi di environment lain. ONNX Runtime Web merupakan implementasi ONNX Runtime yang berjalan di browser menggunakan WebAssembly (WASM), memungkinkan inferensi model deep learning di sisi klien tanpa server backend. Kuantisasi INT8 dinamis pada model ONNX dapat mengurangi ukuran model hingga ~75% dengan dampak

minimal pada akurasi, sehingga sangat cocok untuk deployment di lingkungan dengan keterbatasan bandwidth dan memori.

BAB III

METODOLOGI

Proyek ini mengikuti pipeline end-to-end yang mencakup persiapan dataset, preprocessing dan alignment, fine-tuning dua model transformer, evaluasi, export ONNX, dan pengembangan web demo. Seluruh eksperimen pelatihan dilakukan di Kaggle Notebook menggunakan GPU T4 × 2.



Gambar 3.1. Pipeline sistem SkillScope ID dari data mentah (NERSkill.Id) hingga web demo berbasis ONNX Runtime Web

3.1 Dataset

Dataset yang digunakan adalah NERSkill.Id dalam format CoNLL/BIO. Dataset diparse menjadi daftar kalimat, di mana setiap kalimat berupa pasangan antara daftar token dan daftar label BIO yang bersesuaian. Baris kosong digunakan sebagai pemisah antar kalimat, sedangkan baris tidak valid dicatat ke dalam log. Statistik lengkap dataset ditampilkan pada Tabel 3.1.

Properti	Detail
Nama Dataset	NERSkill.Id
Sumber	Mendeley Data — DOI: 10.17632/5s8r9ndfvc.1
Sumber Lowongan	Indeed, Jobstreet, Loker.id, Job.Id
Total Kalimat	4.299 kalimat
Total Token	418.868 token
Total Entitas	45.508 entitas terannotasi
Format	CoNLL / BIO tagging
Bahasa	Bahasa Indonesia

Tabel 3.1. Statistik Dataset NERSkill.Id

Label BIO	Kategori	Contoh
B-HSkill / I-HSkill	Hard Skill	analisis data, manajemen proyek, digital marketing
B-SSkill / I-SSkill	Soft Skill	kemampuan komunikasi, kepemimpinan, teliti
B-Tech / I-Tech	Technology	Python, MySQL, Laravel, Microsoft Excel
O	Bukan Entitas	dibutuhkan, kandidat, yang, memiliki

Tabel 3.2. Label Entitas pada Dataset NERSkill.Id

Dataset dibagi menjadi tiga split berdasarkan persentase. Split dilakukan pada tingkat kalimat—bukan token—untuk mencegah kebocoran konteks antar split. Random seed 42 digunakan untuk memastikan reproduibilitas.

Split	Proporsi	Jumlah Kalimat	Tujuan
Train	80%	3.439	Melatih parameter model
Validation	10%	430	Memilih checkpoint terbaik, pantau overfitting
Test	10%	430	Evaluasi final (tidak disentuh selama tuning)

Tabel 3.3. Pembagian Dataset

3.2 Preprocessing dan Token-Label Alignment

Karena model transformer menggunakan subword tokenizer WordPiece, satu kata dapat dipecah menjadi beberapa subword token. Untuk menangani hal ini, proses alignment diterapkan dengan aturan: (1) label diberikan hanya pada subword pertama dari setiap kata asli; (2) subword lanjutan diberi label -100 agar diabaikan oleh loss function; dan (3) token spesial [CLS], [SEP], dan token padding diberi label -100 . Tokenisasi menggunakan parameter `is_split_into_words=True`. Analisis distribusi panjang kalimat pada dataset menunjukkan bahwa 78,74% kalimat memiliki panjang di bawah 128 token, sehingga nilai `max_length=128` dipilih untuk menghemat waktu pelatihan hingga $2\times$ lipat dibandingkan `max_length=256` tanpa mengorbankan akurasi secara signifikan.

3.3 Konfigurasi Training

Kedua model dilatih menggunakan konfigurasi identik untuk memastikan perbandingan yang adil. Detail hyperparameter disajikan pada Tabel 3.4. Strategi pelatihan menggunakan `EarlyStoppingCallback` dengan `patience=3`, di mana pelatihan dihentikan apabila F1 validasi tidak mengalami peningkatan selama 3 epoch berturut-turut. Checkpoint yang disimpan adalah yang memiliki F1 validasi tertinggi (`load_best_model_at_end=True`).

Parameter	Nilai	Keterangan
Learning Rate	2e-5	Standar untuk fine-tuning BERT
Batch Size (Train)	8	Disesuaikan dengan VRAM GPU T4 untuk model Large (335M param)
Batch Size (Eval)	16	Lebih besar karena tidak memerlukan gradient computation
Maksimum Epoch	10	Dengan early stopping, epoch efektif bervariasi per model
Weight Decay	0.01	Regularisasi L2 untuk mencegah overfitting
Warmup Ratio	0.1	Mengurangi training shock pada epoch awal
Max Gradient Norm	1.0	Gradient clipping untuk stabilitas training
Early Stopping Patience	3	Hentikan jika F1 validasi tidak meningkat 3 epoch berturut
Max Length (token)	128	Mencakup 78,74% kalimat pada dataset
Random Seed	42	Menjamin reproduibilitas eksperimen

Tabel 3.4. Konfigurasi Hyperparameter Training

3.4 Strategi Evaluasi

Evaluasi dilakukan menggunakan library seqeval yang menghitung metrik pada tingkat entitas (entity-level span), bukan tingkat token. Metrik yang digunakan adalah precision, recall, dan F1-score micro average. Evaluasi per kategori entitas juga dihasilkan untuk memahami performa model pada masing-masing jenis entitas. Test set digunakan hanya satu kali pada evaluasi final setelah seluruh tuning selesai, untuk mencegah data leakage dan memastikan estimasi generalisasi yang valid.

3.5 Export Model ke ONNX

Model terbaik dikonversi ke format ONNX melalui dua tahap: (1) export ke ONNX FP32 menggunakan library Optimum dari HuggingFace, dengan validasi

perbandingan output antara model PyTorch dan ONNX pada sampel data; dan (2) kuantisasi dinamis INT8 menggunakan onnxruntime untuk mengurangi ukuran file. ONNX INT8 Quantized digunakan pada web demo selama tidak terjadi degradasi performa yang signifikan pada contoh inferensi.

3.6 Pengembangan Web Demo


Web demo SkillScope ID dibangun sebagai aplikasi statis menggunakan HTML5, CSS3, dan JavaScript vanilla tanpa framework. Inferensi model dilakukan sepenuhnya di sisi klien (browser) menggunakan ONNX Runtime Web (WebAssembly), sehingga tidak memerlukan server backend. Tokenizer WordPiece diimplementasikan natively dalam JavaScript (app.js) agar kompatibel dengan model yang di-export. Fitur utama mencakup: ekstraksi entitas dengan highlight warna berbeda per kategori, tampilan confidence score per entitas, filter berdasarkan kategori, serta export hasil ke format JSON dan CSV.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Statistik Dataset

Dataset NERSkill.Id terdiri dari 4.299 kalimat dengan total 418.868 token dan 45.508 entitas terannotasi. Distribusi entitas pada test set menunjukkan bahwa kategori Technology (Tech) memiliki jumlah entitas terbanyak (2.498 entitas), diikuti Hard Skill/HSkill (2.288 entitas), dan Soft Skill/SSkill (930 entitas). Ketidakseimbangan distribusi ini berpengaruh langsung pada performa model per kategori, sebagaimana akan dibahas pada subbab 4.3.




Gambar 4.1. Distribusi label entitas pada dataset NERSkill.Id menunjukkan dominasi kategori Tech dan HSkill dibanding SSkill

4.2 Proses Training dan Konvergensi

Kedua model berhasil dilatih hingga konvergen di Kaggle Notebook GPU T4 $\times$ 2. IndoBERT-Large mencapai checkpoint terbaik pada epoch ke-7 dengan total waktu training 4 jam 48 menit. NusaBERT-Large mencapai checkpoint terbaik lebih cepat, yaitu pada epoch ke-4, dengan waktu training 3 jam 22 menit. Perbedaan kecepatan konvergensi ini mengindikasikan bahwa NusaBERT-Large

membutuhkan lebih sedikit pembaruan parameter untuk mencapai performa optimal, kemungkinan karena representasi awal yang lebih kaya akibat volume data pre-training yang lebih besar (16 miliar token vs. IndoBERT).



Gambar 4.2. Kurva training IndoBERT-Large (atas) dan NusaBERT-Large (bawah): validation loss dan validation F1-score per epoch

4.3 Perbandingan Performa Model

Tabel 4.1 menyajikan hasil evaluasi kedua model pada test set menggunakan metrik entity-level micro average dari library sequeval. NusaBERT-Large unggul pada seluruh metrik utama, dengan F1-score 0,7904 berbanding 0,7832 milik IndoBERT-Large.

Model	Precision	Recall	F1-Score	Best Epoch	Waktu Training
IndoBERT-Large	0,7699	0,7969	0,7832	7	4 jam 48 menit
NusaBERT-Large ✓	0,7884	0,7925	0,7904	4	3 jam 22 menit

Tabel 4.1. Perbandingan Performa Model pada Test Set (Entity-Level, Micro Average)

Berdasarkan hasil tersebut, NusaBERT-Large ditetapkan sebagai model final karena unggul pada F1-score (0,7904 vs 0,7832), precision (0,7884 vs 0,7699), dan memiliki waktu training lebih singkat (3j22m vs 4j48m). Selisih F1 sebesar 0,0072 poin absolut secara konsisten ditemukan di seluruh metrik, menunjukkan keunggulan NusaBERT yang bersifat sistematis, bukan kebetulan.

Perlu dicatat bahwa IndoBERT-Large memiliki recall lebih tinggi (0,7969 vs 0,7925), artinya model ini lebih sensitif dalam mendeteksi entitas skill. Namun, hal ini diimbangi dengan precision yang lebih rendah (0,7699 vs 0,7884), yang mengindikasikan adanya lebih banyak false positive—kasus di mana model menandai frasa bukan-skill sebagai entitas. Untuk task ekstraksi skill yang membutuhkan keseimbangan antara keduanya, F1-score tetap menjadi metrik penentu utama.

4.4 Classification Report per Entitas — NusaBERT-Large

Analisis mendalam terhadap performa NusaBERT-Large per kategori entitas pada test set menunjukkan variasi yang signifikan, sebagaimana terlihat pada Tabel 4.2.

Kategori Entitas	Precision	Recall	F1-Score	Support (Entitas)
Hard Skill (HSkill)	0,7095	0,6949	0,7021	2.288
Soft Skill (SSkill)	0,7905	0,8602	0,8239	930
Technology (Tech)	0,8584	0,8567	0,8575	2.498
Micro Average	0,7884	0,7925	0,7904	5.716

Tabel 4.2. Classification Report NusaBERT-Large pada Test Set (Entity-Level)

Kategori Technology (Tech) memiliki F1-score tertinggi sebesar 0,8575 karena nama teknologi seperti Python, SQL, MySQL, Laravel, dan Microsoft Excel cenderung memiliki ciri leksikal yang khas dan konsisten—umumnya berupa kata benda asing atau singkatan yang mudah dikenali oleh model. Kategori Soft Skill (SSkill) memiliki recall tertinggi (0,8602), menunjukkan model cukup mampu mendeteksi entitas soft skill, meskipun ada sejumlah false positive (precision 0,7905). Kategori Hard Skill (HSkill) memiliki performa paling rendah (F1=0,7021) karena batas antara hard skill dan soft skill seringkali ambigu dalam konteks kalimat lowongan kerja.

4.5 Error Analysis

Error analysis dilakukan dengan mengambil sampel prediksi yang salah dari test set untuk mengidentifikasi pola kesalahan model. Empat kategori error utama yang ditemukan adalah:

- (1) False Positive: Model menandai frasa umum sebagai entitas skill, misalnya frasa seperti "menggunakan" yang ditandai sebagai Hard Skill. Terjadi terutama pada frasa yang secara sintaksis mirip dengan entitas dalam data latih.
- (2) False Negative: Model gagal mendeteksi entitas skill, terutama pada hard skill yang diungkapkan dengan frasa multi-kata yang jarang muncul di data training atau menggunakan diksi yang tidak umum.
- (3) Boundary Error: Model mendeteksi entitas yang benar tetapi batas span-nya tidak tepat—misalnya hanya menandai sebagian kata dari entitas multi-kata, seperti menandai "analisis" saja alih-alih "analisis data".
- (4) Label Confusion: Model mendeteksi entitas dengan benar tetapi memberikan kategori yang salah. Pola ini paling sering terjadi antara HSkill dan Tech, misalnya "machine learning" yang kadang diprediksi sebagai Tech alih-alih HSkill.

Pola label confusion antara HSkill dan Tech merupakan tantangan inherent dari dataset ini, karena beberapa skill seperti "machine learning" dan "data science" dapat masuk ke dua kategori sekaligus tergantung konteks dan perspektif anotator. Hal ini menjadi area penting untuk pengembangan dataset di masa mendatang.

4.6 Hasil Export dan Validasi ONNX

Model NusaBERT-Large yang terpilih berhasil dikonversi ke format ONNX melalui dua tahap. Tabel 4.3 menyajikan detail ukuran artefak pada setiap tahap konversi.

Format	Ukuran File	Keterangan
PyTorch (.bin)	~1.280 MB	Model original setelah fine-tuning NusaBERT-Large
ONNX FP32	1.280,78 MB	Export via Optimum; akurasi identik dengan model PyTorch
ONNX INT8 Quantized	321,75 MB	Kuantisasi dinamis; digunakan pada web demo (reduksi 74,87%)


Tabel 4.3. Hasil Export Model dan Ukuran Artefak ONNX

Kuantisasi INT8 berhasil mereduksi ukuran model sebesar 74,87% (dari 1.280,78 MB menjadi 321,75 MB) tanpa degradasi performa yang signifikan secara visual pada contoh inferensi lowongan kerja yang diuji. Validasi dilakukan dengan membandingkan prediksi entitas antara model PyTorch dan model ONNX quantized pada sampel data test set, dan hasilnya menunjukkan konsistensi yang baik. ONNX INT8 Quantized dipilih untuk web demo karena ukurannya yang lebih manageable untuk loading di browser, sesuai dengan acceptance criteria yang telah ditetapkan.

4.7 Tampilan dan Pengujian Web Demo

Web demo SkillScope ID berhasil dibangun dan berjalan secara lokal melalui HTTP server (python -m http.server 8080). Antarmuka menggunakan tema

dark glassmorphism dengan tipografi Inter untuk UI dan JetBrains Mono untuk elemen kode/teknis. Proses loading model di browser membutuhkan waktu 20–60 detik pada percobaan pertama, bergantung pada kecepatan koneksi dan performa perangkat.



Gambar 4.3. Tampilan web demo SkillScope ID menampilkan hasil ekstraksi entitas dengan highlight warna, confidence score, dan panel daftar entitas per kategori

Pengujian menggunakan teks contoh lowongan Data Analyst (PT Nusantara Data) menghasilkan deteksi entitas yang relevan, di antaranya: Python, SQL, Microsoft Excel, Tableau, dan Power BI sebagai kategori Technology; analisis data dan machine learning sebagai Hard Skill; serta komunikasi, problem solving, dan tim sebagai Soft Skill. Confidence score yang ditampilkan bervariasi, dengan kategori Technology umumnya memiliki confidence tertinggi (92–97%), sesuai dengan temuan pada classification report ($F1 \text{ Tech} = 0,8575$). Fitur export ke JSON dan CSV berfungsi dengan baik, dan model berhasil menjalankan inferensi sepenuhnya di browser tanpa koneksi ke server eksternal.

Artefak proyek tersedia pada repositori GitHub: <https://github.com/M-Aidil-Fitrah/UAS-MK-NLP-B>. File model ONNX (~322 MB) tidak disertakan dalam repositori karena ukurannya, tetapi tersedia untuk diunduh melalui tautan Google Drive yang terdapat pada README.md repositori tersebut.

Link Drive: [Google Drive](#)

BAB V

KESIMPULAN

5.1 Kesimpulan

Proyek SkillScope ID telah berhasil membangun sistem ekstraksi skill otomatis dari teks lowongan kerja Indonesia menggunakan Named Entity Recognition berbasis transformer. Berdasarkan eksperimen dan evaluasi yang dilakukan, diperoleh kesimpulan sebagai berikut:

- NusaBERT-Large terbukti unggul dibandingkan IndoBERT-Large untuk task NER ekstraksi skill dari lowongan kerja Indonesia, dengan F1-score micro average 0,7904 berbanding 0,7832. Keunggulan ini konsisten di seluruh metrik evaluasi dan kemungkinan besar merupakan dampak dari data pre-training NusaBERT yang jauh lebih besar (16 miliar token).
- Performa model bervariasi signifikan per kategori entitas: Technology memperoleh F1 tertinggi (0,8575) karena nama teknologi memiliki ciri leksikal yang khas, diikuti Soft Skill (F1=0,8239) dan Hard Skill (F1=0,7021). Label confusion antara HSkill dan Tech merupakan tantangan inherent yang perlu diatasi pada penelitian berikutnya.
- Konversi model ke ONNX INT8 Quantized berhasil mereduksi ukuran file sebesar 74,87% (dari 1.280,78 MB menjadi 321,75 MB) tanpa degradasi performa yang signifikan, memungkinkan deployment di browser.
- Web demo SkillScope ID berhasil dibangun sebagai aplikasi statis yang menjalankan inferensi NER sepenuhnya di browser menggunakan ONNX Runtime Web, tanpa memerlukan server backend, sehingga siap digunakan sebagai live demo.

DAFTAR PUSTAKA

- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of NAACL-HLT 2019*, 4171–4186. <https://doi.org/10.18653/v1/N19-1423>
- LazarusNLP. (2023). NusaBERT-large [Model card]. HuggingFace. <https://huggingface.co/LazarusNLP/NusaBERT-large>
- Mendeley Data. (2023). NERSkill.Id: Named Entity Recognition for skill extraction from Indonesian job postings [Dataset]. <https://doi.org/10.17632/5s8r9ndfvc.1>
- Microsoft. (2024). ONNX Runtime: Cross-platform inference and training machine-learning accelerator. <https://onnxruntime.ai/>
- Nadeau, D., & Sekine, S. (2007). A survey of named entity recognition and classification. *Linguisticae Investigationes*, 30(1), 3–26. <https://doi.org/10.1075/li.30.1.03nad>
- Nakayama, H., Kubo, T., Kamura, J., Taniguchi, Y., & Liang, X. (2018). seqeval: A Python framework for sequence labeling evaluation [Software]. <https://github.com/chakki-works/seqeval>
- Ratinov, L., & Roth, D. (2009). Design challenges and misconceptions in named entity recognition. *Proceedings of CoNLL 2009*, 147–155. <https://doi.org/10.3115/1596374.1596399>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 5998–6008.
- Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Xu, P., Kristian, Y., Vania, C., & Purwarianti, A. (2020). IndoNLU: Benchmark and resources for evaluating Indonesian natural language understanding. *Proceedings of AACL-IJCNLP 2020*, 843–857.

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., & Brew, J. (2020). Transformers: State-of-the-art natural language processing. Proceedings of EMNLP 2020 (System Demonstrations), 38–45. <https://doi.org/10.18653/v1/2020.emnlp-demos.6>